从全局统计到类别几何

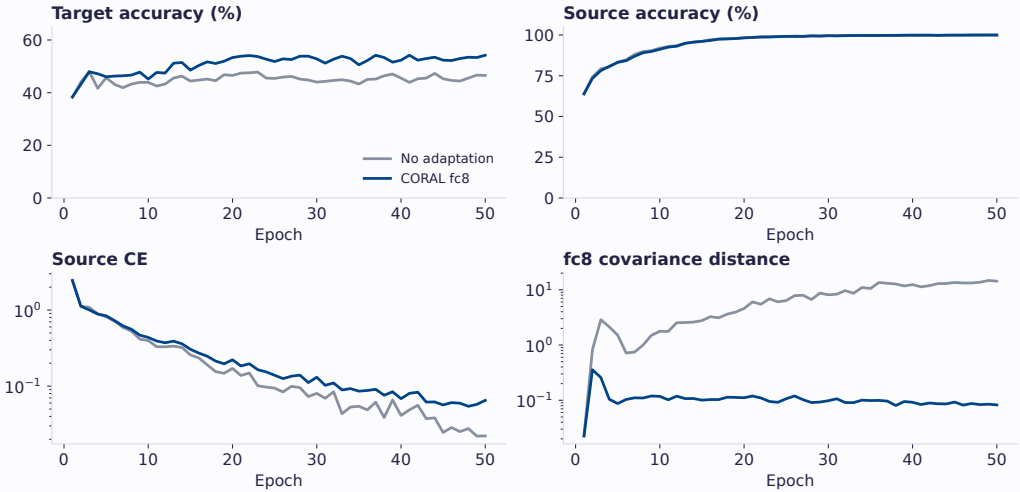
Deep CORAL、子域对齐与 LMMD / DSAN 的实验探索

张以禾

2026 年 10 月 16 日

Office-31 · Amazon → Webcam

Deep CORAL 原实验复现



多层 CORAL 联合对齐

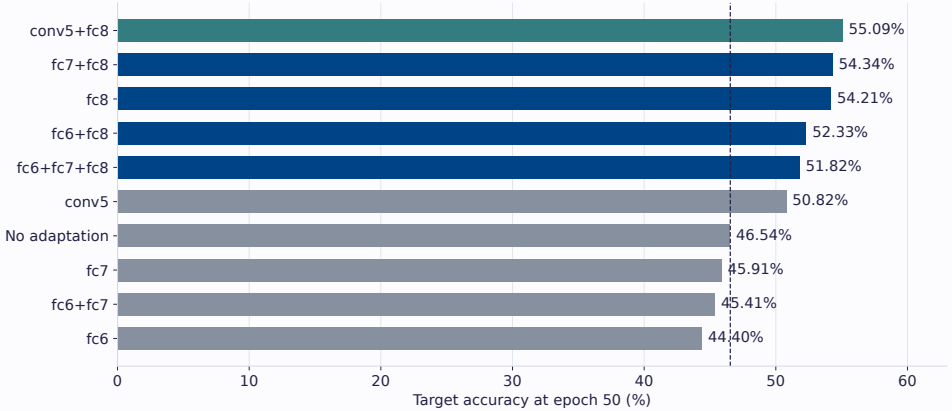
$$\mathcal{L} = \mathcal{L}_{\mathrm{CE}} + \frac{\lambda}{|\mathcal{A}|} \sum_{\ell \in \mathcal{A}} \frac{\|C_s^{(\ell)} - C_t^{(\ell)}\|_F^2}{4D_\ell^2}, \qquad \lambda = 0.5.$$

层	对齐对象	实际损失系数
conv5	空间位置上的 256 维通道特征	单层：0.5
fc6 / fc7	4,096 维 Linear 输出，ReLU 前	双层：各 0.25
fc8	31 维分类 logits	三层：各 $1/6$

- 单层：conv5、fc6、fc7、fc8。
- 联合：conv5+fc8、fc6+fc7、fc6+fc8、fc7+fc8、fc6+fc7+fc8。
- AlexNet V1，Amazon→Webcam，seed=42，batch=128，固定 50 轮。

来源：reports/data/layer_results.csv；多层损失取均值。

多层 CORAL：conv5+fc8 的正确率最高



conv5+fc8：55.09%；fc8：54.21%；无适应：46.54%。更多对齐层没有带来单调改善。

来源：AlexNet 位置实验，第 50 轮目标正确率。

自适应 λ：梯度范数平衡

在共享 conv5 参数上计算梯度范数，EMA decay=0.9；$\lambda = e^{s}$：

$$g_{\mathrm{CE}} = \|\nabla \mathcal{L}_{\mathrm{CE}}\|_2, \quad g_{\mathrm{G}} = \|\nabla \mathcal{L}_{\mathrm{G}}\|_2, \quad \boxed{J_\lambda = (\lambda \overline{g}_{\mathrm{G}} - \overline{g}_{\mathrm{CE}})^2}.$$

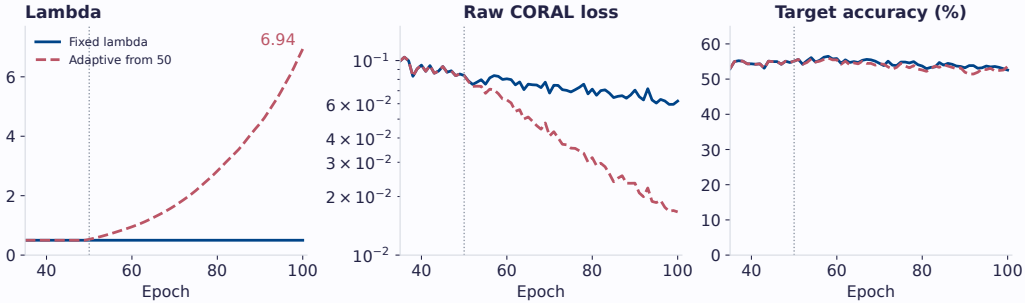
独立 Adam（lr=0.01）学习 s；模型更新时将 λ detach。

配置	最佳正确率	最终正确率	最终 λ
fc8：固定	54.21%	54.21%	0.50
fc8：第 1 轮起自适应	54.97%	51.32%	3.64
fc8：第 41 轮起自适应	54.21%	53.58%	0.87
conv5+fc8：固定	56.48%	52.58%	0.50
conv5+fc8：第 50 轮起自适应	55.97%	53.58%	6.94

全程自适应 fc8 的最终正确率下降；联合组的峰值也没有提高。

来源：reports/data/lambda_results.csv；fc8 为 50 轮，conv5+fc8 为 100 轮。

启用自适应后：λ 激增，CORAL loss 快速下降



- 第 50 轮启用后：λ 从 0.5 升至 **6.94**；原始 $\mathcal{L}_{\mathrm{G}}$ 从 0.0853 降至 **0.0167**。
- 出现 $\mathcal{L}_{\mathrm{G}} \to 0$ 的趋势，与论文强调避免的退化方向一致；对齐值下降未改善最佳正确率。

该自适应方案无效，依然采用固定 $\lambda = 0.5$。

来源：conv5+fc8 逐轮日志；Deep CORAL §3.2 强调分类与对齐约束的平衡。

停止条件：分类损失与加权 CORAL 损失平衡

记每轮训练均值 $a_e = \mathcal{L}_{\mathrm{CE}}$、$b_e = 0.5\mathcal{L}_{\mathrm{G}}$，分别维护 decay=0.5 的 EMA。

$$\delta(a, b) = \frac{|a - b|}{\max(a, b, 10^{-12})}.$$

规则与条件

从第 20 轮起，**当轮与 EMA 的相对差距均** $\leq 25\%$，**连续两轮**满足则停止；最大预算 100 轮。

设计目的：保持固定适应强度，以训练内信号判断两项约束是否达到平衡，减少过长训练。

conv5+fc8 结果：日志回放在第 **58** 轮触发，正确率 **56.48%**；第 100 轮为 52.58%。原始 / EMA 差距分别为 13.17% / 15.72%。

来源：reports/data/early_stop_results.csv；停止信号只读取训练损失。

ResNet-50：CORAL 的额外收益不明显

ImageNet V2，batch=32，共享 BN；$\lambda = 0.5$，双层各 0.25；使用相同停止规则。

配置	停止轮	正确率	同轮对照正确率	同轮增益
No CORAL	100	80.00%	80.00%	+0.00 pp
logits	37	81.01%	78.49%	+2.52 pp
pooled	100	80.38%	80.00%	+0.38 pp
pooled+logits	42	80.25%	78.11%	+2.14 pp
layer4	100	79.87%	80.00%	-0.13 pp
layer4+logits	42	81.76%	78.11%	+3.65 pp

无 CORAL 已达到 **80.00%**；单独 pooled / layer4 对齐基本没有改善，含 logits 的配置有小幅收益。

在这种更先进的预训练网络上，CORAL 并未带来明显的性能跃迁。

来源：reports/resnet50/summary.csv；同轮对照采用一致的共享 BN 配置。

子域对齐：分别匹配同一类别的两域分布

第 c 类子域为源域与目标域中属于该类别的样本；目标类别由模型概率估计。

$$\text{全局对齐}:\mathcal{D}(P_s, P_t) \quad \longrightarrow \quad \text{子域对齐}:\frac{1}{C}\sum_{c=1}^{C}\mathcal{D}(P_s^c, P_t^c).$$

全局统计混合了什么？

整体协方差同时包含类内变化和类间中心结构。

不同类别的域偏移可能相互掩盖。

子域对齐匹配什么？

源域类别 c 对应目标域类别 c，分别建立统计量并对齐。

目标域使用软类别权重，而非真实标签。

$$\mathcal{L} = \mathcal{L}_{\mathrm{CE}} + \lambda\,\mathbb{E}_c[\mathcal{D}(P_s^c, P_t^c)].$$

来源：DSAN，第 III 节：按类别划分相关子域。

参考 DSAN 实现 CORAL 子域对齐

借用 DSAN 的类别软权重，将其统计目标替换为**逐类协方差差异**：

$$p_{jc} = \mathrm{sg}[\mathrm{softmax}(z_j^t)_c], \quad a_{ic}^s = \frac{\mathbf{1}[y_i^s = c]}{\sum_r \mathbf{1}[y_r^s = c]}, \quad a_{jc}^t = \frac{p_{jc}}{\sum_r p_{rc}}.$$

$$\mu_d^c = \sum_i a_{ic}^d z_i^d, \qquad C_d^c = \frac{\sum_i a_{ic}^d (z_i^d - \mu_d^c)(z_i^d - \mu_d^c)^\top}{1 - \sum_i (a_{ic}^d)^2}.$$

$$\boxed{\mathcal{L}_{\mathrm{C}} = \frac{1}{|\mathcal{V}|} \sum_{c \in \mathcal{V}} \frac{\|C_s^c - C_t^c\|_F^2}{4D^2}}.$$

- AlexNet fc8 的 31 维 logits；目标权重 detach，特征路径反传。
- 有效类要求：源支持 ≥ 2、目标 top-1 支持 ≥ 2、目标 ESS ≥ 2。

来源：src/core/subdomain_coral.py；类别权重参考 DSAN，协方差目标为本实验自定义。

CORAL 子域对齐：未产生正向效果

统一初始化、batch=128；适应组前十轮均使用 $0.5\mathcal{L}_{\mathrm{G}}$，第 11 轮切换。

配置	第 11–50 轮适应项	第 50 轮正确率
无适应	0	46.54%
global	$0.5\mathcal{L}_{\mathrm{G}}$	53.84%
global_quarter	$0.25\mathcal{L}_{\mathrm{G}}$	54.09%
local	$0.5\mathcal{L}_{\mathrm{C}}$	42.14%
mixed	$0.25\mathcal{L}_{\mathrm{G}} + 0.25\mathcal{L}_{\mathrm{C}}$	49.56%

- local 相对 global **下降 11.70 pp**。
- mixed 在保留全局系数 0.25 的情况下，仍比 global_quarter **低 4.53 pp**。

更细的类别划分没有改善分类，直接沿用类内协方差目标反而损害正确率。

来源：reports/subdomain_coral/lmmd/summary.csv；均为固定第 50 轮结果。

实验 DSAN 的 LMMD：AlexNet 与 ResNet-50

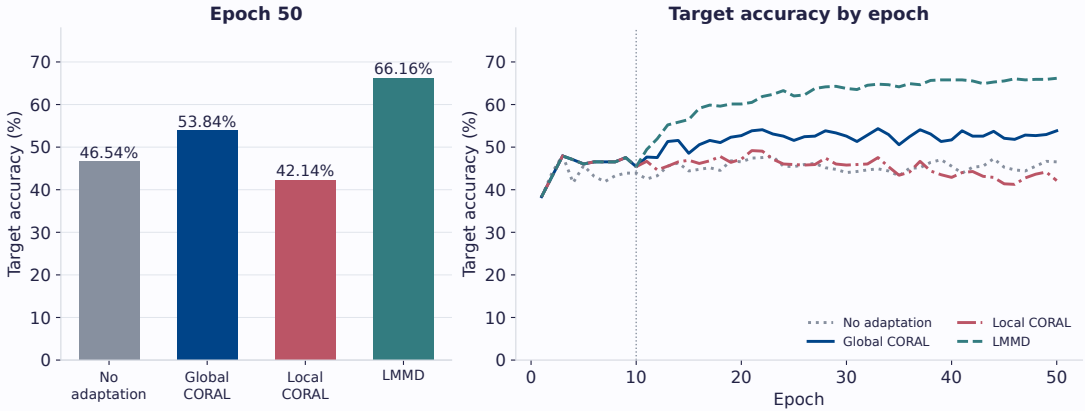
LMMD 沿用类别软权重，匹配同类样本的**核均值嵌入**：$\mathcal{L} = \mathcal{L}_{\mathrm{CE}} + \lambda \mathcal{L}_{\mathrm{LMMD}}$。

	AlexNet	ResNet-50 V2
对齐表示	fc8：31 维 logits	2048 $\rightarrow$ 256 bottleneck $\rightarrow$ 31；对齐 256 维
训练配置	batch=128，6 步 / 轮	batch=32，源域驱动 87 步 / 轮
适应项	前 10 轮 $0.5\mathcal{L}_{\mathrm{G}}$；后 40 轮 $0.5\mathcal{L}_{\mathrm{LMMD}}$	无 CORAL 预热；$\lambda(e)$ 渐增至 0.5
学习率	0.001 / 0.01，固定	0.001 / 0.01 / 0.01，作者衰减
结果选择	固定第 50 轮	每轮目标评估选最佳；30 轮无提升停止

两组均使用作者的**五核 RBF** 与共享类别规则；ResNet 按作者代码使用裁剪 / 翻转且不加 Normalize。

来源：reports/subdomain_coral/lmmd/protocol.md；reports/resnet50_lmmd/protocol.md。

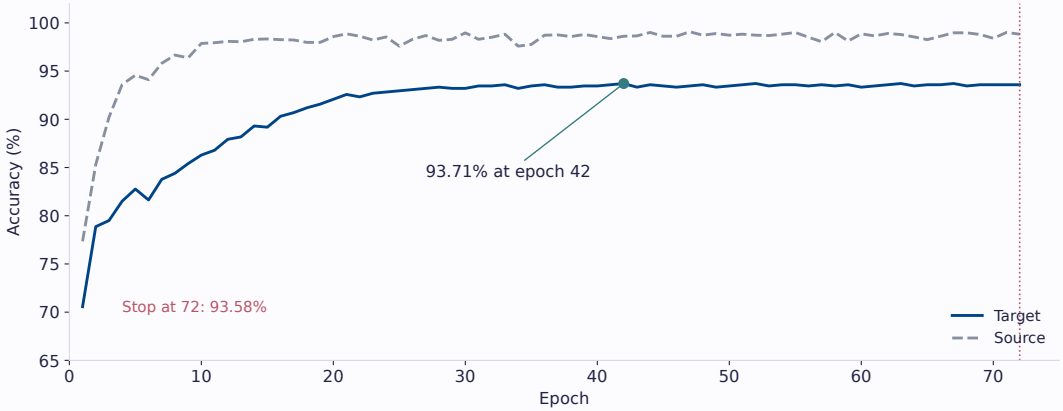
AlexNet + LMMD：正确率提高到 66.16%



固定第 50 轮：全局 CORAL 53.84%，子域 CORAL 42.14%，LMMD 66.16%。

来源：同一 AlexNet / fc8 / 十轮预热配置；LMMD 相对全局 CORAL +12.33 pp。

ResNet-50 + LMMD：最佳正确率 93.71%



第 42 轮最佳 93.71%；第 72 轮停止为 93.58%。

来源：ResNet-50 V2 + 256 维 bottleneck；最佳轮按目标正确率选择；论文 DSAN A→W 为 $93.6 \pm 0.2\%$。

LMMD 的设计：类别条件下的核均值匹配

令 $k(x,y)=\langle\phi(x),\phi(y)\rangle_{\mathcal{H}}$，同类两域的核均值差为

$$\mathcal{L}_{\mathrm{LMMD}}=\frac{1}{|\mathcal{U}|}\sum_{c\in\mathcal{U}}\left\|\sum_{i}a_{ic}^{s}\phi(z_i^{s})-\sum_{j}a_{jc}^{t}\phi(z_j^{t})\right\|_{\mathcal{H}}^{2}.$$

将平方范数展开，得到实际计算形式：

$$M_c=\sum_{i,i'}a_{ic}^{s}a_{i'c}^{s}k(z_i^{s},z_{i'}^{s})+\sum_{j,j'}a_{jc}^{t}a_{j'c}^{t}k(z_j^{t},z_{j'}^{t})-2\sum_{i,j}a_{ic}^{s}a_{jc}^{t}k(z_i^{s},z_j^{t}),\qquad \mathcal{L}_{\mathrm{LMMD}}=\frac{1}{|\mathcal{U}|}\sum_{c}M_c.$$

- 前两项描述域内相似度，交叉项拉近跨域的同类核分布。
- $\mathcal{U}$ 为源真实类别与目标 top-1 类别的交集；域内求和包含对角线。

来源：DSAN，Eq. (5)–(8)；作者 LMMD 实现。

区别一：协方差遗漏类别中心，LMMD 能感知位置差异

固定类别权重时，逐域平移不改变类内协方差：

$$C_a(Z + \mathbf{1}v^\top) = C_a(Z).$$

因此，两域同类可以具有**相同协方差**、**不同中心**，而 $\mathcal{L}_{\mathrm{C}} = 0$。

核均值会检测这种差异

线性核下：$M_c = \|\mu_s^c - \mu_t^c\|_2^2$。

单核 RBF 下，以集中在 $u \neq v$ 的同类分布为例：

$$M_c = k(u,u) + k(v,v) - 2k(u,v) = 2\big(1 - e^{-\|u-v\|^2/\beta}\big) > 0.$$

子域 CORAL 对“类别放在哪里”没有直接约束；LMMD 保留了这类位置信息。

来源：基于两种实际目标函数的推导；$\beta > 0$，同类分布的示例用于说明中心差异。

区别二：RBF 核比较的结构比二阶协方差更充分

类条件 CORAL 只匹配**中心化二阶矩**，相同均值 / 协方差仍可对应不同分布。

$$e^{-\|x-y\|^2/\beta} = e^{-\|x\|^2/\beta} e^{-\|y\|^2/\beta} \sum_{r=0}^{\infty} \frac{(2/\beta)^r}{r!} (x^\top y)^r.$$

RBF 核使用无限维非线性特征，能够区分均值、协方差以外的分布结构。

总体层面的可识别性

固定带宽的高斯核是特征核（characteristic kernel）：

$$\mathrm{MMD}_k^2(P, Q) = 0 \quad \Longleftrightarrow \quad P = Q.$$

同样按类别分组，LMMD 匹配的是更完整的分布信息，而非仅类内波动。

来源：Gretton et al., A Kernel Two-Sample Test (2012), §2；DSAN。

区别三：自适应带宽弱化“只缩小幅度”的捷径

拼接两域批次为 $u_1, \dots, u_n$，作者使用五个核之和：

$$b_0 = \frac{\sum_{r \neq q} \|u_r - u_q\|^2}{n(n-1)}, \quad b = \max(\mathrm{sg}[b_0], 10^{-12}), \quad k(x, y) = \sum_{h=0}^{4} e^{-\|x-y\|^2/(b 2^{h-2})}.$$

固定类别权重，共同缩放 $Z \mapsto sZ$，且每批同步重估带宽：

$$\mathcal{L}_{\mathrm{C}}(sZ_s, sZ_t) = s^4 \mathcal{L}_{\mathrm{C}}(Z_s, Z_t), \qquad \frac{\|sx - sy\|^2}{s^2 b} = \frac{\|x - y\|^2}{b}.$$

- CORAL 的绝对距离可以仅因特征收缩而迅速减小。
- 带宽下限未触发时，LMMD 的核值对共同正缩放保持不变；五核同时覆盖多个距离尺度。
- 这是重估带宽后的前向性质；实现中带宽 detach，目标 softmax 仍每批更新。

LMMD 不会仅因为两域特征一起变小，就在前向数值上得到更好的对齐值。

来源：作者 LMMD 带宽 $b/4, b/2, b, 2b, 4b$：缩放推导以固定权重与正缩放为条件。

区别四：LMMD 更适合类别支持稀疏的小批次

	自实现子域 CORAL	LMMD 作者规则
需要估计的统计量	每类协方差及有限样本修正	每类加权核均值
源域 / 目标支持	各至少 2 个支持样本	共享类各至少 1 个即可
权重集中度限制	目标 ESS ≥ 2	无 ESS 门槛
批内类别利用	先过滤协方差不可靠的类别	可利用单样本共享类

- 类别较多、batch 较小时，LMMD 不必依赖稳定的逐类协方差估计。
- 相同 λ 不代表相同梯度强度；本轮两种目标的支持规则、带宽与优化尺度同时不同。

LMMD 的优势同时来自统计目标和可用类别范围。

来源：src/core/subdomain_coral.py；src/core/lmmd.py。

反思：子域划分不够，还要选对统计目标

方法	正确率	类内协方差距离	类中心方向距离	软权重纯度
Global CORAL	53.84%	0.12058	0.326	0.427
Local CORAL	42.14%	0.01053	0.331	0.229
LMMD	66.16%	0.03481	0.102	0.591

- 子域 CORAL 的协方差距离最小，正确率却最低；**更小的二阶差异不是更好的分类**。
- LMMD 的中心方向更接近、软分组更准确，与其更充分的分布约束相符。
- LMMD 仍要与 CE 联合：全体特征完全相同也会使其为零；类别判别性由分类约束共同维持。

本轮有效的是“类别软分组 + 核分布匹配 + 源域判别”，而非单独把全局 CORAL 拆成逐类 CORAL。

来源：固定第 50 轮事后诊断；方向距离越低越接近，纯度越高越好；目标真值仅用于这些诊断。